Astrit Mustafa

Data Engineer junior · Pipelines, entrepôts de données, SQL, Python

amustafa360@gmail.com
+32 470 17 71 68
Amay (Liège), Belgique · Permis B, véhiculé
astreetm.github.io
github.com/AstreetM
linkedin.com/in/astrit-mustafa

PROFIL

Data engineer junior tourné vers le client, formé à la BI (Technifutur, 2026) après un bachelier E-Business. Chez Wavenet, j'ai conçu et livré un entrepôt de données de plus de 23 millions d'événements pour un client du secteur public : architecture en couches, chargement incrémental optimisé et contrôles qualité automatisés. Je construis des pipelines fiables en partant du besoin du métier, surtout en SQL et en Python, et je configure des agents IA pour le code répétitif, les tests et la documentation, ce qui me laisse plus de temps pour le client.

COMPÉTENCES TECHNIQUES

ENTREPÔTS & MODÉLISATION	PostgreSQL · SQL Server · architecture médaillon (bronze / silver / gold) · modèle en étoile (Kimball) · SCD · chargement incrémental
PIPELINES & TRAITEMENT	SQL avancé (CTE, fonctions de fenêtrage, PL/pgSQL) · optimisation sur gros volumes · Python (pandas, POO) · Airflow · PySpark et Databricks (Auto Loader, Delta, jobs)
QUALITÉ & OUTILLAGE	Contrôles qualité automatisés · pytest · Great Expectations · Git / GitHub (branches, pull requests) · Docker
RESTITUTION	Power BI · DAX · Power Query · Odoo (Studio, tableaux de bord)
IA & AGENTS	Agents IA configurés pour mes projets data : code répétitif, tests, documentation · je garde la main sur le besoin, le modèle et la vérification des chiffres
MÉTHODES	Agile (Scrum) · analyse des besoins métier · documentation technique · formation d'utilisateurs

EXPÉRIENCE

Data & Analytics Engineer (stage)

Août – Oct 2026

Wavenet, Liège · société de conseil IT

ENTREPÔT DE DONNÉES POUR UN CLIENT DU SECTEUR PUBLIC

- **Exploration et profilage** de deux sources (23 millions d'événements, 1,5 million de dossiers) pour cadrer l'analyse des délais de traitement
- Entrepôt PostgreSQL en **architecture médaillon** (bronze, silver, gold) : modèle en étoile, dimensions en SCD de type 1, chargement incrémental des livraisons mensuelles avec dédoublonnage
- Chargement optimisé de **2 h 25 à 11 minutes** par livraison : traitements ensemblistes à la place des boucles ligne à ligne, anti-jointures, agrégations en une seule passe
- Huit **contrôles qualité automatisés** et une table d'anomalies exposée au métier, qui ont chiffré 1,9 million d'incohérences dans les données sources
- Rapport Power BI de sept pages et mesures DAX livré au métier, avec un retour positif du client

REPORTING INTERNE SUR ODOO

- **Chaîne de mise en production des rapports** entre les bases de test et de production : versionnement Git et deux outils Python de contrôle avant import, adoptés par l'équipe
- Analyse des besoins de plusieurs départements, adaptation du modèle de données dans Odoo Studio (champs et champs liés) et tableaux de bord mis en production
- **Formation d'un nouvel employé data analyst** sur Odoo et sur la chaîne de versionnement, avec une documentation de référence

`POSTGRESQL` `SQL` `PYTHON` `GIT` `POWER BI` `QUALITÉ DONNÉES`

Gestionnaire Web & Réseaux sociaux (intérim)

Oct – Nov 2023

City Store, Dison (Liège)

- Gestion et qualité des données CRM · suivi des KPIs de campagnes · SEO et administration web

Assistant Marketing & Commercial (stage)

Sept 2022 – Janv 2023

Foodalix, Bruxelles

- Reporting de KPIs commerciaux · segmentation et qualification des bases clients

PROJETS PERSONNELS · GITHUB.COM/ASTREETM

Ponctualité des trains belges, Databricks · PySpark, SQL, Delta, Auto Loader, Lakeflow Jobs
Pipeline médaillon sur plus de 4 millions de passages de trains (données ouvertes d'Infrabel) : chargement incrémental avec Auto Loader, contrôles et quarantaine en PySpark, modèle en étoile en SQL, job déclenché à l'arrivée de chaque fichier et tableau de bord AI/BI.

Entrepôt analytique et tests qualité, AdventureWorks · SQL Server, Python, pytest
Modélisation en étoile sur 172 000 lignes, quatre axes d'analyse, 34 tests automatisés validant la cohérence et la traçabilité des volumes.

FORMATION

Consultant Business Intelligence
Technifutur & Cefora, Seraing (Liège)
Janv 2026 – Juin 2026
SQL · Python · modélisation Kimball · Airflow · Power BI · projet ETL en équipe sous Git

Bachelier E-Business / Digital Business
Haute École de la Province de Liège (HEPL)
Sept 2018 – Fév 2023
Bases de données · ERP & CRM · BPMN · Agile

LANGUES

Français Langue maternelle
Anglais Intermédiaire (B1)

CERTIFICATION

Google Analytics IQ
Juillet 2022